全澍

13719348235 quanshu@stu.pku.edu.cn

教育背景

北京大学 · 深圳研究生院 · 硕士 环境科学 GPA：3.61/4 **2024.09 – 2027.06（预计）**

科研方向：LLM安全评估与AI对齐 | 北京大学人工智能研究院 · PKU-Alignment组（导师：杨耀东教授）

访问研究：LLM幻觉检测与缓解 | 香港科技大学（广州）人工智能学院 · NLP-LAB（导师：胡旭明教授）

河南大学 · 地理与环境学院 · 本科 地理信息科学 GPA：3.68/4（排名 1/46） **2020.09 – 2024.06**

英语水平：CET-6、雅思6.5 核心课程：计算机程序设计、数据结构、数据库原理、概率论与数理统计

专业技能

- **训练与对齐**: 熟悉SFT、LoRA、偏好数据构建、Reward Model、DPO/RLHF、GRPO等LLM后训练流程；理解pointwise/pairwise偏好建模、rubric奖励信号、安全约束权衡。
- **数据与评测**: 擅长Benchmark构建、LLM-as-Judge、细粒度rubric评估、幻觉检测、红队攻击、人工抽检校准与case-level错误归因，能将开放任务拆成可训练、可评估、可复核的结构化信号。
- **实验与工程**: 使用Python、PyTorch、Transformers、vLLM、LangGraph。运用DeepSpeed加速框架、Llama-Factory等流行训练框架。

科研经历

LLM功能风险量化：多阶段级联Verifier框架设计与安全分类器训练 2025.06 – 2026.02

- **核心工作**：针对"自然语言拒答率无法量化LLM真实功能危害"的评测盲区，设计多阶段级联SPIKE评测框架并定义FHR聚合指标，训练领域专用安全分类器，完成32个LLM的大规模系统性审计。
- **多阶段级联Verifier设计**：将输出风险判别解构为三阶段串联Pipeline。Stage 1通过合规分类器过滤自然语言层响应；Stage 2接入蛋白质语言模型ESM-2（伪困惑度评分）与ESMFold（结构折叠置信度）对生成序列做生物学可行性验证；Stage 3通过毒性分类器预测功能危害概率；三阶段级联输出构成FHR指标，将定性"有害"转化为连续可比的定量风险信号。
- **安全分类器训练**：以BioLinkBERT-large为backbone微调专域分类器BioSafe-Guard，构建无重叠测试集并做阈值校准、过拒率分析与backbone消融（对比通用BERT/RoBERTa），验证领域预训练对保留良性可用性的关键作用；检测率**98.9%**，良性过拒率仅**0.3%**，将全部32个模型FHR降至$\leq$0.5%。
- **大规模审计与规律发现**：系统审计32个LLM，分析拒答率、生成能力与FHR三者相关性；发现传统拒答率与真实功能风险近零相关（$r \approx -0.05$，$p = 0.79$），FHR最高达**50.7%**，揭示现有安全对齐的系统性盲区，为后训练安全策略提供实证依据。

第一作者，投稿至 **COLM 2026**（审稿中）

SafeCLI：CLI Agent系统安全评测框架设计与基准构建 2025.10 – 2026.03

- **项目背景**：将CLI Agent建模为受约束的POMDP，针对现有轨迹级评估无法捕获OS底层隐蔽风险的问题，提出系统级安全检测框架与推理策略，发现**74%**系统故障为"静默失败"，初始违规使后续有害行为增加**21.43%**。
- **OS-Monitor框架设计**：设计首个内核级插拔式Agent安全检测框架——将7类系统风险（权限滥用、安全控制绕过、数据外泄等）分解为28个可独立部署的自动化检测器；选择auditd、procfs与sysfs作为探测源，实现步级实时检测，将OS底层状态转化为可量化的process-level安全信号。
- **SafeCLI基准构建**：设计并构建SafeCLI基准，覆盖314个Linux CLI任务与13个风险场景，系统对比轨迹级与系统级评估的偏差；基于OS-Monitor信号为后续agent policy训练提供步级监督信号基础。

第三作者，投稿至 **NeurIPS 2026**（审稿中）

多智能体协作的科学文献数据提取框架 2024.09 – 2025.09

- 解决语言模型在复杂材料科学文献中提取结构化数据时准确性与鲁棒性不足的挑战。设计多智能体协作生成（三条独立推理路径产出多样化候选）、生成-判别评估（结合蒙特卡洛树搜索对候选结果进行全面质量排序）及双重交叉验证机制，提升真实科学文献结构化抽取准确率。

- **结果**：BulkModulus数据集准确率达92.85%，MatSynTriplet达77.68%，在无需微调的设置下超过单路径与传统基线。

第三作者，发表于 **npj Computational Materials**（SCI Q1）

实习经历

OPPO-大模型算法部　大模型算法实习生 | DeepResearch多轮规划与长文本事实性评估　2025.06 – 2025.10

- **核心工作**：针对DeepResearch长文本报告生成中的规划退化与事实幻觉问题，将单步大纲生成重构为多轮反思的agentic规划链路，设计配套的离线评测框架与策略消融体系，提升复杂开放问题下的规划稳定性与事实可靠性。
- **规划策略优化**：将原"大纲生成"升级为"意图识别→子任务分解→规划反思→执行校验"链路；围绕不同backbone、temperature/Top-p、反思轮次与prompt模板做对照实验，定位任务遗漏、粒度失衡、不可检索子问题等失败模式。
- **长文本事实性评估信号**：设计统计数值、引用来源、上下文一致性三类事实性错误标签，构建URL可达性、来源内容一致性与代码执行校验流程，将主观质量评价转化为可定位的case-level监督信号，用于judge prompt迭代与策略选择。
- **实验闭环**：基于LangGraph将规划、检索、生成、验证模块拆分为可插拔节点，支持单模块替换、ablation与回归测试；任务规划满意度提升5%，长文本事实准确率从**60%**提升至**78.5%**。

科大讯飞-华南研究院　大模型算法实习生 | 医疗LLM细粒度Reward Modeling与GRPO对齐 2025.02 – 2025.05

- **核心工作**：设计医疗LLM细粒度对齐体系的核心算法模块，将粗粒度偏好信号重构为可量化、可注入的多维训练信号，支撑Qwen3-8B模型RM训练与GRPO对齐实验；项目整体准确率提升**22.3%**，安全合规提升**21.7%**，在专家盲审基准上与前沿闭源模型持平。
- **三元层级Rubric Schema设计**：将医疗回答质量建模为三个正交维度——主评分S_1（医学正确性/推理合理性/信息完整性的加权聚合）、优秀加分S_2（逻辑连贯性/共情质量等卓越属性）与安全否决S_3（幻觉/有害内容的硬约束）；设计词典序偏好比较协议（S_3绝对优先）将安全约束从性能增益中硬解耦，防止RLHF中的奖励黑客现象。
- **Explicit Criteria Injection训练范式**：针对传统scalar RM无法区分细粒度临床失败模式的问题，设计将rubric标准显式注入RM训练目标的范式：将偏好对按rubric维度展开为多维监督信号，训练criteria-conditioned多维Reward Model；以该多维RM为奖励源驱动GRPO训练，实现能力提升与安全约束的精确解耦控制。
- **偏好数据Pipeline**：设计ProMedical-Preference-50k构建流程，融合医学知识抽取、权威数据库检索与证据级交叉验证生成instruction-specific rubric标准；结合人工盲审校准闭环，错误检测精度从**65.5%**提升至**82.6%**，抽检合格率从**80%**提升至**95%**以上。

算法竞赛

Kaggle竞赛：面向LLM评审系统的多维度对抗攻击　2024.12 – 2025.03

- 设计多维度攻击框架，利用不同LLM评委的逻辑、能力及身份差异实现评分操控：通过矛盾指令利用解析差异、植入功能指令分离模型行为、模型身份识别与定向攻击。
- **成果**：1692支队伍中获**银牌**（排名76，Top 5%），验证了黑盒LLM攻防场景下的框架有效性。

阿里天池竞赛：新闻推荐算法　2024.09 – 2024.12

- 基于30万用户、36万文章、600万+点击数据，设计多路召回体系（优化ItemCF + Word2Vec语义向量 + 时间窗口策略）与LightGBM排序模型，构建29维用户-物品交互特征。最终HR@5达0.479，MRR@5达0.291，相比基础方案**提升约25%**。

获奖情况

- 河南省优秀毕业生　2024.06
- 国家奖学金　2023.09